

Análisis Espacio-Temporal del Rendimiento del Arroz Mecanizado y Eventos Aleatorios de Precipitación en los departamentos de meta y casanare, Colombia.

Paola Andrea Ruiz Franco¹

¹Universidad Nacional de Colombia, Sede Medellín, Colombia

* Correspondence:

Corresponding Author

paruizf@unal.edu.co

Keywords: Análisis espacio-temporal, Rendimiento agrícola², Interacciones clima-agricultura³, Modelado espacial⁴.

Abstract

El análisis del rendimiento de cultivos como el del arroz, cobra especial relevancia en la actualidad debido a la recurrencia de eventos climáticos extremos que afectan directamente la producción agrícola. El arroz es un cultivo clave para la seguridad alimentaria. Por esta razón, se encuentra relevante estudiar mediante una exploración inicial, la relación entre la precipitación y el rendimiento del arroz mecanizado en departamentos como Meta y Casanare. Estos territorios cuentan con registros históricos consolidados entre 2013 y 2023, a partir de las encuestas realizadas por el DANE en conjunto con Fedearroz. El análisis incluye una revisión temporal de variables como precipitación y rendimiento, el estudio estadístico de otras variables relevantes, la exploración espacial a través de mapas, el análisis de correlación entre variables implicadas y la aplicación de modelos espaciales como ICAR y GWR. También se incorpora la validación cruzada de los modelos empleados.

1 Introduction

Si bien el cambio climático es un fenómeno natural y cíclico, la variabilidad climática que estamos experimentando en diferentes regiones del mundo se ha vuelto cada vez más extrema (Kumar et al., 2022). En los últimos 20 años se han intensificado tanto las sequías como las precipitaciones severas (Kumar et al., 2022). La seguridad alimentaria se ve directamente afectada porque depende en gran medida del comportamiento del clima (Sihi et al., 2022). Colombia no es la excepción frente a los problemas de disminución en el rendimiento de cultivos, especialmente los cereales (Díaz, 2025). Colombia produce la mayor parte de la demanda de arroz que consume, en 2021, el 99% del consumo aparente de arroz en Colombia fue atendido por la producción nacional, mientras que las importaciones cubrieron el 1% restante. Los datos del análisis de producto de arroz sugieren que Colombia tiene una fuerte dependencia de su producción interna para satisfacer su demanda, cubriendo casi la totalidad de su consumo, aunque su productividad por hectárea no siempre supera a la de otros países importantes en el sector (Gerencia Corporativa de Analítica y Estudios Económicos, s. f.).

El arroz, como cereal fundamental en la canasta básica de alimentos, representa un componente esencial de la seguridad alimentaria en muchos países, incluido Colombia. Además de su

relevancia nutricional, el arroz constituye una fuente principal de ingreso económico para miles de familias rurales en distintas regiones del país. Alrededor de 400,000 familias en al menos 210 municipios de Colombia dependen del cultivo de arroz (Gerencia Corporativa de Analítica y Estudios Económicos, s. f.). Su producción es especialmente sensible a las condiciones climáticas debido a que, en sus distintos ciclos fenológicos, requiere una cantidad precisa de agua para garantizar un desarrollo adecuado (Gerencia Corporativa de Analítica y Estudios Económicos, s. f.). Existen umbrales hídricos mínimos y máximos que deben cumplirse, ya que tanto el déficit como el exceso de agua pueden afectar significativamente la productividad del cultivo. Por esta razón, el análisis detallado de la precipitación en zonas productoras específicas permite identificar riesgos potenciales y comprender mejor los factores que están contribuyendo a la disminución de los rendimientos agrícolas (Elahi et al., 2022; Gerencia Corporativa de Analítica y Estudios Económicos, s. f.).

Varios estudios han abordado los cultivos de cereales desde una perspectiva geoespacial, empleando diversas metodologías para analizar su producción, los impactos climáticos y las estrategias de adaptación. Se han utilizado imágenes satelitales (Landsat, Sentinel-2) y tecnologías GIS y Teledetección (RS) para estimar y pronosticar el rendimiento de cultivos como trigo, arroz y patata (Raihan, 2024). Un estudio combinó datos multispectrales de Landsat con índices espectrales para cuantificar la cubierta de paja de trigo y su impacto en el rendimiento del arroz. Otro estudio pronosticó los rendimientos de trigo de invierno en China con 1-2 meses de antelación utilizando datos climáticos, del suelo e imágenes RS en la plataforma Google Earth Engine (GEE) (Raihan, 2024; Yang et al., 2022).

Para el análisis de la relación entre la precipitación y el rendimiento del arroz mecanizado en los departamentos de Meta y Casanare, se emplearon herramientas tecnológicas y fuentes de datos que permiten abordar el fenómeno desde una perspectiva espacio-temporal. Entre ellas se destaca el uso de Google Earth Engine (GEE), plataforma que facilita el acceso y procesamiento de datos climáticos satelitales, en este caso a partir del conjunto de datos CHIRPS (Climate Hazards Group InfraRed Precipitation with Station data), que ofrece registros de precipitación desde 1981.

La información agrícola utilizada proviene de registros oficiales del DANE, en conjunto con Fedearroz, que reportan los rendimientos de arroz mecanizado por municipio para los años 2013 a 2023. A partir de esta integración de fuentes, fue posible aplicar análisis estadísticos, exploración espacial y modelos como la Regresión Ponderada Geográficamente (GWR) y el modelo ICAR (Intrinsic Conditional AutoRegressive), con el fin de identificar patrones geográficos y posibles correlaciones entre variables climáticas y agrícolas.

Este enfoque permite tener una visión preliminar de cómo se comportan los rendimientos en relación con la precipitación en regiones clave del país, aportando elementos para mejorar la comprensión de los impactos del clima sobre la seguridad alimentaria.

Este estudio tiene como objetivo explorar el comportamiento espacio-temporal del rendimiento del arroz mecanizado en Colombia entre 2013 y 2023, con énfasis en los departamentos de Meta y Casanare. Para ello, se integran datos agrícolas (DANE, FEDEARROZ), climáticos satelitales (CHIRPS) y geográficos procesados con Google Earth Engine (GEE), y se aplican métodos estadísticos y espaciales como regresión logística, modelos ICAR, GWR, autocorrelación espacial y kriging exploratorio. El análisis busca identificar factores asociados al bajo

rendimiento y comprender su distribución territorial, como una primera aproximación a la relación entre condiciones climáticas y productividad en zonas clave del país.

2 Metodología

2.1. Recolección e integración de datos

El dataset para el análisis de la relación espacial entre precipitación y rendimiento fue construido a partir de datos de arroz mecanizado a nivel municipal para los departamentos de Meta y Casanare, con base en las encuestas realizadas por el DANE en conjunto con FEDEARROZ entre los años 2013 y 2023. Estos datos iniciales contenían, para cada departamento, un municipio asociado, área sembrada (ha), rendimiento (ton/ha), año y semestre (I o II).

Con esta base, se integraron las series temporales de precipitación disponibles en el repositorio satelital CHIRPS (Climate Hazards Group InfraRed Precipitation with Station data), procesadas con Google Earth Engine y agregadas como valores acumulados semestrales (en mm) para cada municipio, año y semestre entre 2013 y 2023. Esta agregación permite analizar la relación entre los volúmenes totales de lluvia en cada ciclo agrícola y el rendimiento del cultivo de arroz mecanizado. Las coordenadas de los polígonos asociados a cada municipio también fueron procesadas con Google Earth Engine.

La variable Bajo_Rendimiento se definió como los valores inferiores al promedio general de los rendimientos, con una clasificación binaria en donde los valores de $Rend < 0.3507$ se codificaron como 1 y los valores $Rend \geq 0.3507$ como 0. Para la precipitación, el valor asignado a la variable `precipitacion_baja` está ligado a todos los valores inferiores al umbral requerido para garantizar el correcto crecimiento de la cosecha de arroz.

2.2 Exploración especial y temporal de los datos (visualización geográfica inicial)

Se exploró la evolución temporal del rendimiento promedio del arroz mecanizado por departamento, junto con la precipitación media mensual. Se calcularon estadísticas descriptivas para todas las variables, incluyendo desviación estándar, valores máximos, mínimos y promedios anuales, con el fin de obtener una lectura preliminar del comportamiento de los datos. Además, se visualizaron las series temporales y diagramas de caja (boxplots) desagregados por semestre.

El análisis espacial se llevó a cabo para identificar patrones geográficos de bajo rendimiento en cultivos de arroz. Luego de haber construido el `GeoDataFrame` para usar con `geopandas`, con coordenadas geográficas de latitud y longitud bajo el sistema de referencia espacial EPSG:4326 (WGS 84), se generaron mapas de dispersión georreferenciada para las variables de bajo rendimiento y precipitación acumulada.

2.3 Diagnóstico de autocorrelación especial (*AnalisisGeoespacial/Notebooks at main · edieraristizabal/AnalisisGeoespacial*, s. f.)

Para poder aplicar modelos espaciales, es necesario verificar si existe dependencia espacial en los datos, es decir, verificar si los valores de rendimiento agrícola en un municipio están relacionados con los de sus municipios vecinos. Por esto, se construyó la matriz tipo Queen, una matriz de pesos espaciales cuyo criterio es la contigüidad. Seguido, se aplicó el Índice de

Moran Global, si bien este valor obtenido fue positivo, no fue concluyente para describir completamente la estructura espacial de los datos, por esta razón, el análisis se complementó con el método LISA (Local Indicators of Spatial Association), que permitió identificar agrupamientos locales significativos (hotspots y coldspots) de bajo rendimiento.

Este diagnóstico es clave para justificar la aplicación de modelos espaciales. Por un lado, la existencia de dependencia espacial local motiva el uso de modelos ICAR, que permiten capturar los efectos espaciales residuales que no explican directamente las variables independientes, pero que reflejan patrones geográficos persistentes.

2.4 Modelado estadístico de base (modelo no especial)

Se comenzó con un modelo estadístico clásico para establecer una línea base sin estructura espacial, la Regresión Logística. El objetivo al realizar este modelado es identificar los factores que influyen en la posibilidad de obtener un bajo rendimiento en el cultivo de arroz mecanizado, considerando variables climáticas, temporales y territoriales.

La elección de la regresión logística se debe a que la variable de interés —Bajo_Rendimiento— es de naturaleza binaria (1 = rendimiento bajo, 0 = rendimiento no bajo). Este tipo de modelo permite estimar la probabilidad de que ocurra un evento (en este caso, bajo rendimiento), en función de un conjunto de variables explicativas o predictoras.

Las variables independientes incluyeron:

- Departamento: permite capturar posibles diferencias regionales entre Meta y Casanare.
- Área sembrada: puede reflejar economías o deseconomías de escala.
- Año y semestre: consideran cambios en el tiempo y posibles efectos estacionales.
- Precipitación acumulada promedio y la variable `precipitacion_alta`: permiten evaluar el impacto de las condiciones climáticas sobre la producción.

Para preparar los datos, las variables categóricas se codificaron usando OneHotEncoder, eliminando la primera categoría para evitar problemas de multicolinealidad. El modelo fue entrenado con el 70% de los datos (457 muestras) y probado con el 30% restante (197 muestras).

2.5 Modelado especial Avanzado

Dada que los datos cuentan con autocorrelación espacial, se aplicaron modelos que incorporan explícitamente la dimensión espacial:

- **Modelos ICAR (Intrinsic Conditional Autoregressive):**

Se implementaron modelos bayesianos ICAR con estructura de vecindad basadas en polígonos adyacentes, utilizando el paquete INLA en R. Se estimaron dos versiones, dada la naturaleza de las variables y con el propósito de explicar los patrones espaciales residuales, o las dependencias geográficas que no se logran explicar por los modelos lineales.

- ICAR Binomial: Fue utilizado para modelar la probabilidad de ocurrencia de “bajo rendimiento”, la cual era una variable binaria: 1 = bajo rendimiento, 0 = rendimiento aceptable. Dado que, este modelo permite tener en cuenta que el rendimiento en una zona puede estar influenciado o afectado por lo que ocurre en las zonas vecinas. Lo que permite mejorar la estimación de las probabilidades de “bajo rendimiento” es precisamente tener en cuenta la relación espacial.
- ICAR Gaussiano: Luego de aplicar el modelo a una variable binaria y observados sus resultados, se aplicó el modelo Gaussiano para la variable continua “rendimiento”. Este enfoque ayuda a evitar que el modelo subestime la incertidumbre en las estimaciones, especialmente cuando hay diferencias importantes entre regiones. El modelo gaussiano con componente espacial suaviza las predicciones en zonas con pocos datos y hace que el modelo sea más estable frente a variaciones espaciales.

En ambos casos (modelo binomial y gaussiano), se evaluó qué tan bien funcionaban los modelos usando los criterios DIC y WAIC, que permiten comparar modelos complejos penalizando su sobreajuste. Gracias a la inclusión de los efectos espaciales, fue posible capturar patrones geográficos que no se explicaban solo con las variables originales, mejorando así la precisión y la comprensión regional del fenómeno.

- **Regresión Geográficamente Ponderada (GWR):**

Complementario a los modelos ICAR, que modelan efectos espaciales no observados mediante componentes aleatorios, se aplicó un modelo de Regresión Geográficamente Ponderada (GWR) con el objetivo de analizar la variación espacial de los coeficientes de regresión asociados a cada predictor. A diferencia del enfoque ICAR, que supone un único conjunto de parámetros globales e introduce la dimensión espacial a través de efectos aleatorios estructurados, GWR permite estimar coeficientes locales para cada unidad espacial (municipio), proporcionando una aproximación exploratoria y descriptiva de la heterogeneidad espacial en las relaciones entre predictores y la variable respuesta.

2.6 Interpolación especial mediante Kriging

Se aplicó kriging ordinario sobre el rendimiento continuo con el fin de generar una superficie interpolada que permitiera visualizar la distribución espacial del fenómeno más allá de las unidades de análisis disponibles. Esta interpolación tuvo un propósito exploratorio, como complemento a los modelos espaciales, y buscó identificar posibles gradientes regionales no visibles en los mapas agregados por municipio.

Aunque una alternativa más robusta habría sido aplicar Kriging sobre los residuos de un modelo ajustado (por ejemplo, ICAR o GWR) para evaluar patrones espaciales no explicados, en este caso se optó por aplicar el método directamente sobre la variable respuesta, con fines descriptivos y de apoyo a la interpretación espacial general.

3 Resultados

3.1 Resultados exploratorios y visualización espacial inicial

Al graficar los boxplots del rendimiento por departamento, se observa que la producción de arroz mecanizado en Casanare es notablemente superior a la de Meta, con valores medianos más altos y menor dispersión. En contraste, los rendimientos en Meta presentan mayor variabilidad y una mayor proporción de valores bajos.

La precipitación acumulada muestra una distribución aproximadamente normal, con una media de 1378.5 mm y una desviación estándar de 328.2 mm. Aunque la mayoría de los registros se concentran alrededor de la media, se observan tanto valores muy bajos (mínimo de 561 mm) como valores extremos altos (máximo de 2455 mm), lo que sugiere la presencia de eventos climáticos atípicos en ciertos periodos o municipios.

En cuanto al histograma de distribución del rendimiento, se evidencia una fuerte asimetría hacia la derecha, con una concentración de observaciones en valores bajos y un número reducido de casos con rendimientos elevados. Esto indica que, en general, los rendimientos tienden a ser bajos en la mayoría de las observaciones, con solo algunos municipios alcanzando niveles óptimos de producción.

La Figura 1 muestra un resumen visual de estas distribuciones mediante histogramas y boxplots, lo que permite identificar de manera preliminar las diferencias entre regiones y el comportamiento general de las variables analizadas.




Figura 1. Estadísticas descriptivas

En la Figura 2, podemos apreciar el comportamiento temporal de la precipitación vs el rendimiento, y encontramos cómo hay ocasiones en las que, a pesar de precipitaciones altas, también tenemos rendimientos altos, demostrando que no necesariamente en todos los municipios el rendimiento es inversamente proporcional a la precipitación. Sin embargo, en términos generales, esto sí ocurre: en la relación precipitación vs rendimiento se observa que, a mayor precipitación acumulada, menor es el rendimiento. Esto motiva el estudio espacial local para detectar patrones espaciales y correlaciones entre las variables.




Figura 2. Visualización temporal del comportamiento de la precipitación y el rendimiento

La Figura 3, permite identificar concentraciones espaciales de bajo rendimiento. Se puede observar aglomeración de puntos críticos en el norte del departamento de Casanare, lo que indica que varios municipios contiguos presentan simultáneamente rendimientos bajos. En el departamento del Meta, estos puntos de bajo rendimiento aparecen mas dispersos, no forman clústeres definidos. Esto sugiere que mientras que en Casanare el bajo rendimiento está geográficamente concentrado, en Meta puede estar asociado a factores más localizados o heterogéneos.




Figura 3. Representación geográfica de dispersión tipo heatmap de rendimiento del arroz en los departamentos de Meta y Casanare.

Los **mapas cloropleta** por municipio mostraron que los promedios semestrales de rendimiento tienen una variabilidad espacial clara, con zonas crónicamente por debajo del umbral de 0.3507 ton/ha.




Figura 4. Mapa coroplético del rendimiento promedio del arroz mecanizado por municipio (2013–2023).

3.2 Diagnóstico de autocorrelación espacial

El Índice de Moran Global fue positivo y estadísticamente significativo, confirmando que los valores de bajo rendimiento no son independientes espacialmente.

I de Moran^{**}: 0.1623

Z-score^{**}: -0.8969

Pseudo p-valor^{**}: 0.0720 (basado en 999 permutaciones)

El análisis LISA permitió identificar clústeres espaciales significativos. Los mapas de la Figura 5, muestran los resultados del análisis LISA (Indicadores Locales de Asociación Espacial). En el primer mapa (LISA de rendimiento), se identifican agrupamientos de municipios con altos rendimientos rodeados de otros altos (alto-alto), principalmente en el norte de Casanare, mientras que otras zonas aparecen como bajo-bajo, lo que indica rendimientos consistentemente bajos entre vecinos.

En el segundo mapa (bajo rendimiento), se confirma esta idea, destacando agrupaciones de municipios que comparten niveles bajos de productividad. En el tercero (precipitación alta), se observa cómo las zonas con mayor lluvia no coinciden necesariamente con los clústeres de bajo rendimiento, lo que refuerza la idea de que la relación entre precipitación y rendimiento varía según el contexto local.




Figura 5. Mapas LISA de variables agrícolas y climáticas en Meta y Casanare.

(a) Rendimiento continuo del arroz mecanizado.

(b) Bajo rendimiento (variable binaria).

(c) Precipitación acumulada.

Los mapas muestran agrupamientos espaciales significativos (*hotspots* y *coldspots*) según el análisis LISA.

3.2 Resultados del modelo estadístico (regresión logística)

La matriz de confusión mostró que el modelo clasificó correctamente 67 de 74 observaciones negativas (clase 0) y 121 de 123 positivas (clase 1), con solo 9 errores en total.

Clase	Precision	Recall	F1-score	Soporte
0	0.97	0.91	0.94	74
1	0.95	0.98	0.96	123
Accuracy		0.95		197

El modelo de regresión logística mostró un buen desempeño predictivo sobre el conjunto de prueba, alcanzando una exactitud del **95%** y un área bajo la curva ROC (**AUC = 0.987**), lo que indica una alta capacidad para distinguir entre municipios con y sin bajo rendimiento. Además, la precisión y el recall fueron altos para ambas clases, con una exactitud global del 95%.

Este modelo sirvió como **modelo base (baseline)** antes de aplicar modelos espaciales más avanzados, y permitió **identificar patrones generales y variables con mayor efecto sobre la probabilidad de bajo rendimiento**.

La **matriz de confusión** evidenció una baja tasa de error, clasificando correctamente 67 de 74 observaciones con rendimiento normal y 121 de 123 con bajo rendimiento.

Entre las variables explicativas, los efectos más notorios se observaron en:

- El **Departamento** Meta, que presentó una fuerte asociación negativa con el bajo rendimiento (coef = -3.18), lo cual indica menor probabilidad de bajo rendimiento en comparación con el departamento de referencia.
- Los **años recientes** (2021–2023) mostraron coeficientes positivos, lo que sugiere una mayor probabilidad de bajos rendimientos en estos periodos respecto al año base.
- El **semestre II** también presentó un efecto positivo, indicando que los cultivos en la segunda mitad del año tendieron a tener un mayor riesgo de bajo rendimiento.
- La variable **precipitacion_alta** presentó un coeficiente negativo, indicando que eventos de alta precipitación se asociaron con menor probabilidad de bajo rendimiento, posiblemente debido a una mayor disponibilidad hídrica.

En conjunto, estos resultados destacan la utilidad del modelo para identificar patrones espacio-temporales y climáticos asociados a la disminución del rendimiento agrícola.

- **Se encontró que:**
 - El **segundo semestre y los años recientes (2021–2023) aumentan la probabilidad de bajo rendimiento.**
 - El **departamento de Meta actúa como un factor protector (coeficiente negativo y significativo).**
 - La variable **“precipitación alta” tiene un efecto significativo sobre el rendimiento.**

El modelo tuvo un ajuste razonable, pero dejó residuos estructurados espacialmente, lo que motivó el uso de modelos espaciales.




Figura 6. Coeficientes estimados en el modelo de regresión logística para predecir bajo rendimiento del arroz mecanizado. Se incluyen intervalos de confianza para cada variable explicativa. Valores positivos indican mayor probabilidad de bajo rendimiento, mientras que valores negativos actúan como factores protectores.

3.3 Resultados de los modelos espaciales bayesianos (ICAR) y (GWR)

LA figura 7, muestra los resultados obtenidos para los modelos ICAR. Se pueden hacer varias observaciones relevantes sobre su desempeño y utilidad. En el caso del modelo ICAR binomial, que busca estimar la probabilidad de bajo rendimiento, las métricas de ajuste obtenidas (DIC = 138.34, WAIC = 149.23 y log-likelihood = -10.68) muestran que el modelo logra capturar cierta variabilidad espacial, pero el ajuste no es óptimo. El número de parámetros efectivos (p.d = 58.48) sugiere una estructura compleja, posiblemente con variables redundantes o poco informativas. Además, el mapa resultante de este modelo presenta una clasificación binaria muy restringida, lo cual podría deberse tanto al desbalance en la variable binaria de bajo rendimiento como a la limitada capacidad explicativa de las variables incluidas.

En contraste, el modelo ICAR gaussiano, que estima directamente el rendimiento como variable continua, muestra un desempeño significativamente mejor. Las métricas DIC (-506.83), WAIC (-518.38) y log-likelihood (373.75) reflejan un excelente ajuste, y aunque el modelo también cuenta con un número elevado de parámetros (p.d = 120.33), estos no comprometen la calidad del ajuste. Este modelo permite capturar bien los patrones espaciales en el rendimiento, en general, se espera que las predicciones reflejen adecuadamente las zonas con alto y bajo rendimiento, aportando una base sólida para inferencias generales a escala regional.




Figura 7. Resultados de los modelos espaciales ICAR aplicados al rendimiento del arroz mecanizado.

(a) Probabilidad estimada de bajo rendimiento (modelo ICAR binomial).

(b) Rendimiento esperado como variable continua (modelo ICAR gaussiano).

Ambos modelos incorporan la estructura espacial de los datos y permiten identificar patrones geográficos no explicados por los predictores originales, mejorando la interpretación regional del fenómeno.

Por su parte, los resultados del modelo de Regresión Geográficamente Ponderada (GWR) mostrados en la Figura 8, permite explorar cómo varían los efectos de los predictores según la ubicación geográfica. A diferencia de los modelos ICAR, que estiman efectos globales con un componente espacial, el GWR genera un conjunto de coeficientes locales por municipio, capturando mejor la heterogeneidad espacial. Por ejemplo, el coeficiente local para precipitación acumulada varía entre -0.00025 y 0.00011, lo que indica que en algunas zonas la lluvia afecta

negativamente el rendimiento, mientras que en otras tiene un efecto levemente positivo. La variable de precipitación alta también presenta variabilidad considerable (-0.1629 a 0.0946), lo que refuerza la importancia del contexto local. Por otro lado, el área sembrada muestra un efecto positivo consistente, aunque débil, en todo el territorio. Los residuales presentan valores muy bajos y centrados en cero (media = 0.0008), lo cual indica un buen ajuste general del modelo.




Figura 8. Resultados del modelo de Regresión Geográficamente Ponderada (GWR) aplicado al rendimiento del arroz mecanizado. Se presentan los coeficientes locales estimados para las variables de precipitación acumulada, área sembrada y semestre, junto con el R^2 local. Los mapas reflejan la variación espacial en la magnitud y dirección del efecto de cada predictor sobre el rendimiento, así como la capacidad explicativa del modelo en cada municipio.

En conjunto, estos modelos permiten abordar el fenómeno del rendimiento agrícola desde distintas perspectivas. El modelo ICAR gaussiano se destaca por su capacidad predictiva global. El GWR por su utilidad para la interpretación y toma de decisiones locales. El ICAR binomial, aunque menos efectivo en este caso, ofrece un enfoque válido para caracterizar eventos críticos si se mejora su especificación o se agregan variables predictoras.

3.4 Resultados de aproximación a Kriging

Como medida de aproximación Kriging, se obtuvieron dos mapas mostrados en la Figura 8. El primer mapa muestra la interpolación del rendimiento estimado mediante Kriging, generando una superficie continua donde se puede ver cómo varía el rendimiento entre puntos. Se aprecian zonas de alto rendimiento hacia el norte y centro, y menores al sur. El segundo mapa presenta la incertidumbre asociada a esas estimaciones, es decir, el error estándar. Las áreas con mayor incertidumbre están en zonas periféricas, donde hay menos datos observados, lo cual sugiere que ahí se necesita más monitoreo o recolección de datos.




Figura 8. Resultados de la interpolación por kriging del rendimiento del arroz mecanizado en Meta y Casanare.

(a) Mapa del rendimiento esperado, generado mediante kriging ordinario.

(b) Mapa de la incertidumbre asociada a las predicciones.

Ambos productos se presentan como una aproximación exploratoria que permite visualizar tendencias espaciales generales y ubicar zonas con menor confiabilidad en las estimaciones.

4 Discusión

Aplicar técnicas de análisis geoespacial avanzadas a problemáticas que incluyen variables climáticas o puntos geográficos ayuda en una escala superior a comprender la particularidad de cada problema, de cada variable y su comportamiento con las demás variables que afectan un fenómeno, en contextos más locales, comprendiendo cada zona como el resultado de lo que ocurre a sus vecinos más cercanos. En este problema específico, se profundizó en comprender la relación entre precipitación y rendimiento agrícola en los departamentos de Meta y Casanare. Aunque el estudio no incluyó variables predictoras como temperatura, tipo de suelo o prácticas agrícolas, si permitió observar como en algunos lugares los niveles altos de precipitación afectan el rendimiento agrícola, aunque no fuera el mismo patrón para cada área estudiada, es decir, indicó que no porque los datos globales mostraran una relación inversa entre precipitación vs rendimiento, esto sería verdad para cada municipio estudiado.

Es importante entender de fondo la filosofía de cada modelo espacial aplicado, puesto que las técnicas o modelos disponibles requieren de algún modo manipulación de los datos o arreglos de las variables,

y esto altera los resultados, en el sentido de que habrá un resultado diferente por cada persona que construya un modelo de análisis de datos. Y comprender el alcance o resultados ofrecidos por cada modelo, permite indirectamente reconocer el factor de error o incertidumbre, el cual explica mucho más y es más valioso en la búsqueda de comprender los fenómenos físicos de cualquier problema.

Este estudio es una aproximación superficial al problema de la incidencia de la variabilidad climática en la seguridad alimentaria. Se debe robustecer el dataset, ampliando el estudio a mas zonas con cultivos de arroz, e incluir mas variables predictoras o explicativas, si lo que se busca es que obtener información precisa y proponer lineamientos de mitigación al riesgo climático.

5 Conclusiones y Recomendaciones

Los resultados obtenidos permiten afirmar que el rendimiento del arroz mecanizado en los departamentos de Meta y Casanare presenta una estructura espacial significativa, evidenciada por la autocorrelación positiva detectada a través del Índice de Moran Global y el análisis LISA. Estas agrupaciones espaciales de bajo rendimiento, especialmente concentradas en ciertas zonas del norte de Casanare, justifican la aplicación de modelos espaciales avanzados como los modelos bayesianos ICAR y la regresión geográficamente ponderada (GWR), los cuales ofrecieron un mejor ajuste y mayor capacidad explicativa frente al modelo estadístico base.

La relación entre la precipitación y el rendimiento del cultivo no es homogénea a lo largo del territorio analizado. Mientras que en algunos municipios mayores acumulados de lluvia se asocian con mejores rendimientos, en otros, este mismo factor tiene un efecto negativo,

posiblemente debido a condiciones particulares relacionadas directamente con el manejo agronómico. El modelo GWR permitió identificar esta variabilidad espacial en los coeficientes, lo cual resalta la importancia de hacer lecturas o propuestas de estrategias de adaptación diferenciadas por región, en lugar de aplicar enfoques climáticos generalizados.

Además, la interpolación por kriging permitió generar una superficie continua del rendimiento, útil como herramienta exploratoria para visualizar gradientes espaciales y complementar los resultados obtenidos por los modelos. El mapa de incertidumbre asociado sugiere zonas con menor confiabilidad en las predicciones, lo cual puede orientar futuros esfuerzos de medición o análisis más detallados en esas áreas.

En conjunto, este trabajo aporta una aproximación metodológica integrada que combina análisis estadístico, espacial y geoestadístico, permitiendo una lectura más precisa y contextualizada del rendimiento agrícola en relación con las condiciones climáticas. Los resultados obtenidos pueden servir como base para la formulación de estrategias regionalizadas de adaptación al cambio climático en sectores agrícolas sensibles como el cultivo de arroz.

• Acknowledgments

This work was conducted under the guidance of Professor Edier Aristizábal as part of the Geospatial Analysis course.

6 Referencias

AnalisisGeoespacial/Notebooks at main · edieraristizabal/AnalisisGeoespacial. (s. f.). Recuperado

25 de julio de 2025, de

<https://github.com/edieraristizabal/AnalisisGeoespacial/tree/main/Notebooks>

Díaz, J. (2025, mayo 21). *Fenalce, 2024*. <https://fenalce.co/en-2024-colombia-disminuyo-las-areas-de-siembra-y-produccion-de-cereales-y-leguminosas/>

Elahi, E., Khalid, Z., Tauni, M. Z., Zhang, H., & Lirong, X. (2022). Extreme weather events risk to crop-production and the adaptation of innovative management strategies to mitigate the risk: A retrospective survey of rural Punjab, Pakistan. *Technovation*, 117, 102255. <https://doi.org/10.1016/j.technovation.2021.102255>

Gerencia Corporativa de Analítica y Estudios Económicos. (s. f.). *Análisis de producto Arroz*. Bolsa Mercantil de Colombia.

- 433 Kumar, L., Chhogyel, N., Gopalakrishnan, T., Hasan, M. K., & Jayasinghe, S. L. (with
434 Kariyawasam, C. S., Kogo, B. K., & Ratnayake, S.). (2022). *Climate change and future of*
435 *agri-food production*. Elsevier. <https://doi.org/10.1016/b978-0-323-91001-9.00009-8>
- 436 Raihan, A. (2024). A Systematic Review of Geographic Information Systems (GIS) in Agriculture
437 for Evidence-Based Decision Making and Sustainability. *Global Sustainability Research*,
438 3(1), 1-24. <https://doi.org/10.56556/gssr.v3i1.636>
- 439 Sihi, D., Dari, B., Kuruvila, A. P., Jha, G., & Basu, K. (2022). Explainable Machine Learning
440 Approach Quantified the Long-Term (1981–2015) Impact of Climate and Soil Properties on
441 Yields of Major Agricultural Crops Across CONUS. *Frontiers in Sustainable Food Systems*,
442 6. <https://doi.org/10.3389/fsufs.2022.847892>
- 443 Yang, L., Driscoll, J., Sarigai, S., Wu, Q., Chen, H., & Lippitt, C. D. (2022). Google Earth Engine and
444 Artificial Intelligence (AI): A Comprehensive Review. *Remote Sensing*, 14(14), 3253.
445 <https://doi.org/10.3390/rs14143253>

446

447 **1 Data Availability Statement**

448 The datasets [GENERATED/ANALYZED] for this study can be found in the [NAME OF
449 REPOSITORY] [LINK]. Please see the “Availability of data” section of [Materials and data policies](#)
450 [in the Author guidelines](#) for more details.